

Relatório Técnico: Classificação de Espécies Iris via KNN

Disciplina:	Fundamentos de Inteligência Artificial
Alunos:	Arthur Xavier, Felipe Souto, Julliane Di Paula
Professor:	Maelso Bruno
Turma:	P7 B – Manhã

1. Análise Exploratória do Dataset

O **Iris Dataset** contém medidas físicas de flores de três espécies: *Setosa*, *Versicolor* e *Virginica*. São 150 amostras (50 por classe), cada uma descrita por 4 atributos numéricos:

- Comprimento da sépala (cm)
- Largura da sépala (cm)
- Comprimento da pétala (cm)
- Largura da pétala (cm)


Objetivo do modelo: prever a espécie de uma flor a partir das suas medidas físicas.

Relevância: todos os atributos são numéricos contínuos, o que torna o cálculo de distâncias diretamente aplicável, sem transformações adicionais.

2. Justificativa do Pré-processamento

- **Verificação de missing values:** Nenhum valor ausente foi encontrado (0 nulos). Necessária pois valores ausentes causariam erros no cálculo das distâncias.
- **Label Encoding:** Os rótulos categóricos ('Setosa', etc.) foram convertidos para inteiros (0, 1, 2). Necessário pois o KNN opera sobre valores numéricos.
- **Padronização — StandardScaler:** Os atributos possuem escalas diferentes (ex: comprimento da pétala varia de 1 a 6,9 cm; largura da sépala de 2 a 4,4 cm). Sem padronização, features com maior magnitude dominariam o cálculo de distâncias, enviesando o modelo. O StandardScaler transforma cada feature para média ≈ 0 e desvio padrão ≈ 1 . O fit foi aplicado *somente* nos dados de treino para evitar data leakage.
- **Divisão treino/teste (80/20 estratificada):** 120 amostras para treino e 30 para teste, mantendo a proporção das classes em ambos os conjuntos.

3. Gráfico de Desempenho



4. Conclusão

Melhor combinação (K + Distância):

As métricas **Chebyshev** e **Minkowski (p=3)** atingiram acurácia de **100%** nos valores K = 11 a K = 14, sendo as melhores combinações encontradas.

Sinais de overfitting com K baixo:

Em K=1, o modelo classifica com base em um único vizinho. Embora a acurácia no conjunto de teste tenha sido de 97%, K=1 apresenta alta variância: pequenas perturbações nos dados de entrada podem alterar a classificação.